

# Le moteur de recherche, inspirateur technologique du Big Data?

Emmanuel Keller, CEO OpenSearchServer





## Ainsi naquît Google...

# The Anatomy of a Large-Scale Hypertextual Web Search Engine

Sergey Brin and Lawrence Page

Computer Science Department, Stanford University, Stanford, CA 94305, USA sergey@cs.stanford.edu and page@cs.stanford.edu

#### **Abstract**

In this paper, we present Google, a prototype of a large-scale search engine which makes heavy use of the structure present in hypertext. Google is designed to crawl and index the Web efficiently and produce much more satisfying search results than existing systems. The prototype with a full

#### **Avril 1998**

http://infolab.stanford.edu/pub/papers/google.pdf





#### Google 1.0

#### 24 millions de pages

"It is foreseeable that by the year 2000, a comprehensive index of the Web will contain over a billion documents."

#### **PageRank**

« Also, a PageRank for 26 million web pages can be computed in a few hours on a medium size workstation. »





### Google 1.0

Storage Statistics	
Total Size of Fetched Pages	147.8 GB
Compressed Repository	53.5 GB
Short Inverted Index	4.1 GB
Full Inverted Index	37.2 GB
Lexicon	293 MB
Temporary Anchor Data (not in total)	6.6 GB
Document Index Incl. Variable Width Data	9.7 GB
Links Database	3.9 GB
Total Without Repository	55.2 GB
Total With Repository	108.7 GB

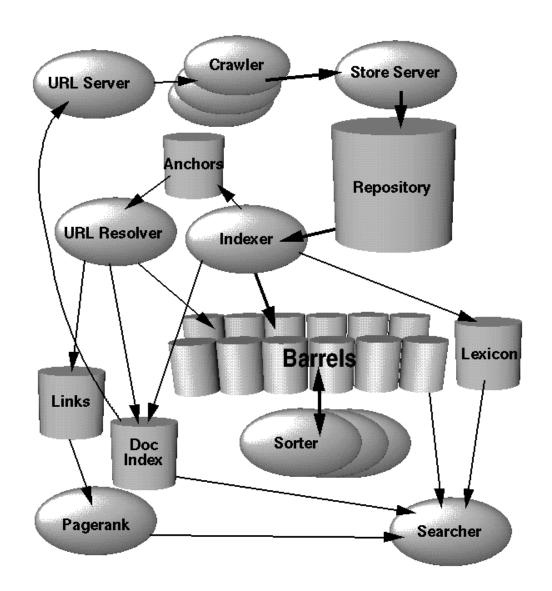


1997 - IBM Deskstar 16GP

« We intend to speed up Google considerably through distribution and hardware, software, and algorithmic improvements »



## Google 1.0







## Rappel

## Informatique n.f.

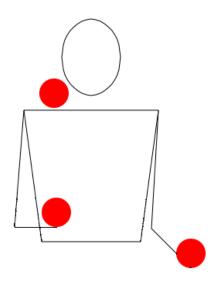
Science du traitement automatique et rationnel de l'information mettant en œuvre des matériels et des logiciels.



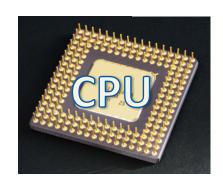


## L'art de jongler...













## ...c'est pas nouveau

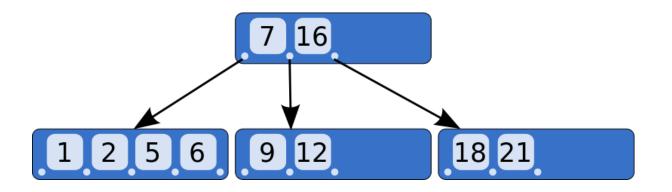
Bayer, Rudolf; McCreight, E. (July 1970),
Organization and Maintenance of Large
Ordered Indices, Mathematical

 Bayer, Rudolf (1971), "Binary B-Trees for Virtual Memory »

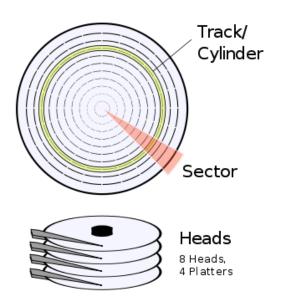




#### La structure en arbre



Réduire le nombre de lectures physiques sur le disque dur







#### Une forêt d'arbres

- Un système de fichiers (FAT, NTFS, EXT3, ZFS) est avant tout une structure en arbre.
- Les bases de données basent leurs index sur la taille des blocs du disque dur
- La mémoire virtuelle





#### Quand au calcul

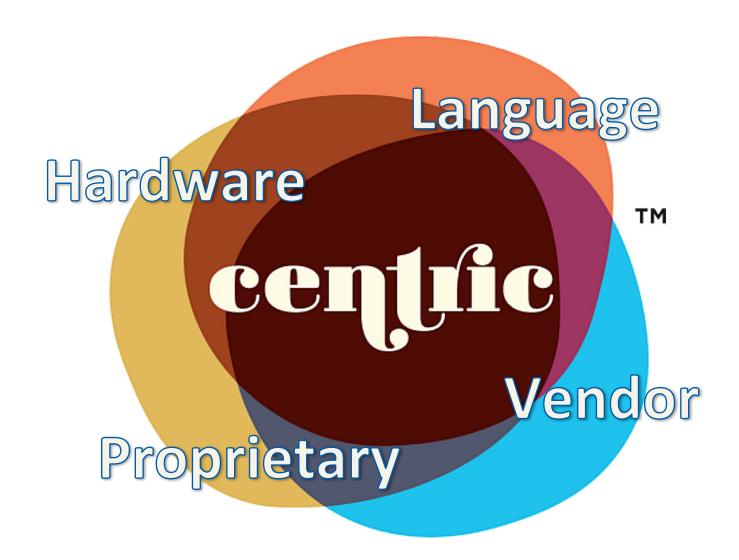
 Les fondeurs peinent à suivre la loi de Moore: la technologie du silicium atteint ses limites

 Les cœurs multiples compliquent les développements: obligation d'intégrer le parallélisme





## Distributed computing







### Google 2.0

#### MapReduce:

« Simplified Data Processing on Large Clusters »

By Jeffrey Dean and Sanjay Ghemawat (Google Inc.)

San Francisco, CA, December, 2004

http://research.google.com/archive/mapreduce.html

Hadoop: Implémentation open source sous licence Apache 2.0







### Map Reduce

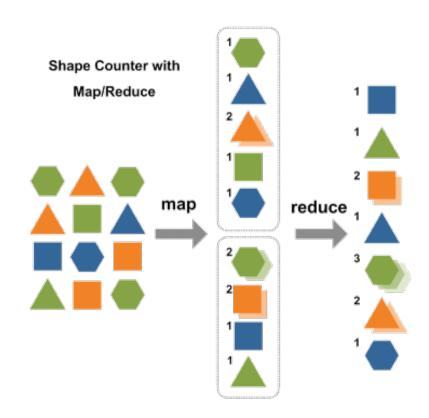
MAP Répartir la charge sur plusieurs nœuds

(WORK)

Chaque nœud travaille sur une partie des données

#### **REDUCE**

Le résultat de chaque nœud est consolidé pour constituer le résultat final



Source: http://www.gridgainsystems.com





#### No SQL Database

- Une approche simplifiée de l'accès aux données
- Principe Clé / Valeur
- Se « cloudise » très bien

Redis, HBase, Cassandra, Mongo DB, MemCache DB, Berkeley DB, Big Table,...

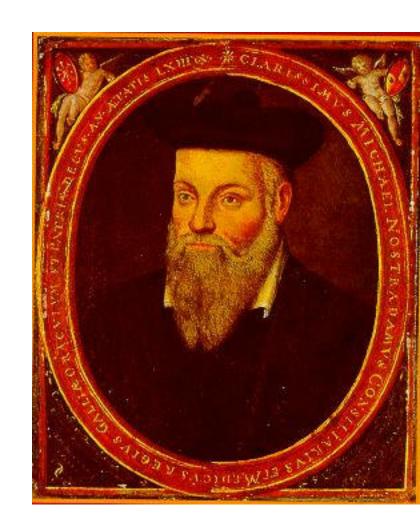






## Vers un nouveau paradigme

- Applications (Pentaho)
- JAVA, C / C++ ? ⊗
- API, API, API, API...
- Système de fichiers
  - XtreemFS
  - Sector/Sphere
  - Oracle Clustered FileSystem (GPL !!!!)
  - Disques SSD







#### Q & A

Merci pour votre attention

ekeller@open-search-server.com

